

## Exploration Numérique 2

25 septembre 2022

Soit  $\{(X_i, Y_i)\}_{i=1}^n$  une suite de  $n$ -échantillons d'une loi gaussienne bivariable de moyenne nulle et de matrice de covariance

$$\Sigma = \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix}$$

où  $\rho \in (-1, 1)$ . Le coefficient de corrélation empirique  $R_n$  est donné par

$$R_n = \frac{S_{n,XY}^2}{S_{n,X}S_{n,Y}} \text{ où } S_{n,XY}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)(Y_i - \bar{Y}_n) \quad S_{n,X}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \quad S_{n,Y}^2 = \frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y}_n)^2$$

1. Montrer que  $\mathbb{E}_\rho[X_1^4] = \mathbb{E}_\rho[Y_1^4] = 3$  et  $\text{Var}_\rho(X^2) = \text{Var}_\rho(Y^2) = 2$ .
2. Montrer que, sous  $\mathbb{P}_\rho$ ,  $Y = \rho X + \sqrt{1 - \rho^2}Z$  où  $Z$  et  $X$  sont indépendants. En déduire

$$\mathbb{E}_\rho[X_1^2 Y_1^2] = 1 + 2\rho^2$$

3. Montrer que

$$\text{Cov}_\rho(X_1^2, X_1 Y_1) = \text{Cov}_\rho(Y_1^2, X_1 Y_1) = 2\rho.$$

Pour  $i \in \mathbb{N}$ , nous notons  $U_i = [X_i^2, Y_i^2, X_i Y_i]^T$ ,  $\mu(\rho) = \mathbb{E}_\rho[U_1]$ .

4. Montrer que pour tout  $\rho \in ]-1, 1[$ ,  $\mu(\rho) = [1, 1, \rho]^T$  et

$$\sqrt{n}(\bar{U}_n - \mu) \xrightarrow{\mathbb{P}_{n,\rho}} N(0, V(\rho))$$

où

$$V = \begin{pmatrix} 2 & 2\rho^2 & 2\rho \\ 2\rho^2 & 2 & 2\rho \\ 2\rho & 2\rho & 1 + \rho^2 \end{pmatrix}$$

5. En déduire que

$$\sqrt{n}([S_{n,X}^2, S_{n,Y}^2, S_{n,XY}^2] - \mu) \xrightarrow{\mathbb{P}_{n,\rho}} N(0, V(\rho))$$

6. Montrer [en utilisant la forme multivariée de la Delta-méthode] que, pour tout  $\rho \in ]-1, 1[$ ,

$$\sqrt{n}(R_n - \rho) \xrightarrow{\mathbb{P}_{n,\rho}} N(0, (1 - \rho^2)^2)$$

Pour construire un intervalle de confiance asymptotique, nous utilisons une technique de stabilisation de la variance

7. Montrer que

$$g(\rho) = \int \frac{1}{1-\rho^2} d\rho = \int \left[ \frac{1/2}{1-\rho} + \frac{1/2}{1+\rho} \right] d\rho = \frac{1}{2} \log \frac{1+\rho}{1-\rho}.$$

8. En déduire que, pour tout  $\rho \in ]-1, 1[$ ,

$$\sqrt{n} \left[ \frac{1}{2} \log \frac{1+R_n}{1-R_n} - \frac{1}{2} \log \frac{1+\rho}{1-\rho} \right] \xrightarrow{\mathbb{P}_{n,\rho}} Z \sim N(0, 1).$$

9. Soit  $\alpha \in ]0, 1[$ . Posons  $W_n = g(R_n)$ . Montrer que

$$\left( \frac{\exp \{2(W_n - z_{(1-\alpha/2)}/\sqrt{n})\} - 1}{\exp \{2(W_n - z_{(1-\alpha/2)}/\sqrt{n})\} + 1}, \frac{\exp \{2(W_n + z_{(1-\alpha/2)}/\sqrt{n})\} - 1}{\exp \{2(W_n + z_{(1-\alpha/2)}/\sqrt{n})\} + 1} \right) \quad (1)$$

est un intervalle de confiance asymptotique de probabilité de couverture  $1 - \alpha$ .

On peut bien entendu construire un intervalle de confiance asymptotique par Studentization.

10. Montrer que

$$\left( R_n - \frac{z_{(1-\alpha/2)}(1-R_n^2)}{\sqrt{n}}, \quad R_n + \frac{z_{(1-\alpha/2)}(1-R_n^2)}{\sqrt{n}} \right) \quad (2)$$

est un intervalle de confiance asymptotique de probabilité de couverture  $1 - \alpha$ .

En statistique, le test de Shapiro–Wilk teste l’hypothèse nulle selon laquelle un échantillon est issu d’une population normalement distribuée ; voir [Shapiro and Wilk, 1972]. Pour le test, vous utiliserez `scipy.stats.shapiro()`. Vous utiliserez aussi `scipy.stats.probplot()` pour les  $q - q$ -plots.

Nous considérons des tailles d’échantillons  $n = 100, n = 200, n = 300$ . Nous répétons pour chaque taille d’échantillons les expériences  $N = 1000$  pour  $\rho = 1/3$ .

1. Visualisez les histogrammes, les boxplots, les quantile-quantile plot de

$$\sqrt{n}(R_n - \rho) \quad \text{et} \quad \sqrt{n} \left[ \frac{1}{2} \log \frac{1+R_n}{1-R_n} - \frac{1}{2} \log \frac{1+\rho}{1-\rho} \right]$$

et calculer les  $p$ -valeurs du test de Shapiro–Wilks. Que conclure ?

2. Calculer les intervalles de confiance asymptotique par les formules (1) et (2). Qu’observe-t-on ?

## Références

[Shapiro and Wilk, 1972] Shapiro, S. S. and Wilk, M. (1972). An analysis of variance test for the exponential distribution (complete samples). *Technometrics*, 14(2) :355–370.